

UNIVERSIDAD PRIVADA “FRANZ TAMAYO”
FACULTAD DE INGENIERÍA
CARRERA DE INGENIERÍA EN SISTEMAS



PROYECTO DM, FASE 2: COMPRENSIÓN DEL NEGOCIO
IDENTIFICACIÓN DE FACTORES ASOCIADOS AL ACCESO A INTERNET EN
VIVIENDAS DEL DEPARTAMENTO DE LA PAZ MEDIANTE CLASIFICACIÓN
BINARIA

DOCENTE: Ing. Enrique Alejandro Laurel Cossio

INTEGRANTES: Galilea Alíson Llusco Asistiri
Alex Quispe Ticona
Alejandro Villalpando Rojas
Cristopher Iori Lazcano Gutierrez
Limber Soto Cazu

MATERIA: Minería de Datos

LA PAZ – BOLIVIA

2026

I. COMPRENSIÓN DEL NEGOCIO

1. Información General del Equipo

Nombre del proyecto. Identificación de factores asociados al acceso a Internet en viviendas del departamento de La Paz mediante clasificación binaria.

Sector e industria. Telecomunicaciones, desarrollo social y planificación pública.

Integrante	Rol	Responsabilidad
Galilea Alison Llusco Asistiri	Fuentes y documentación	Gestionar las fuentes y documentar su carga y trazabilidad.
Alex Quispe Ticona	Comprensión de datos	Realizar la exploración inicial y verificar métricas y denominadores.
Alejandro Villalpando Rojas	Preparación de datos	Limpiar, transformar e integrar la información a nivel de hogar.
Cristopher Iori Lazcano Gutierrez	Modelado y evaluación	Entrenar, comparar e interpretar modelos de clasificación binaria.
Limber Soto Cazu	Coordinación general	Coordinar el equipo y mantener la relación con el problema de negocio.

Tabla 1. Distribución de responsabilidades del equipo
Fuente. Elaboración propia.

2. Definición del Problema de Negocio

2.1 Contexto y problemática actual. La disponibilidad de Internet en La Paz cambia de forma marcada entre áreas urbanas y rurales. La falta de conectividad limita el acceso a educación, información, empleo, trámites y otros servicios digitales, mientras que la ausencia de un diagnóstico predictivo dificulta orientar los recursos hacia los hogares con mayor probabilidad de exclusión digital.

2.2 Objetivo de negocio. Apoyar la reducción de la brecha digital en el departamento de La Paz mediante la identificación de factores asociados a la disponibilidad de Internet en las viviendas, de modo que las estrategias de conectividad y priorización territorial se sustenten en evidencia.

2.3 KPI de negocio. Porcentaje de viviendas con acceso a Internet fijo o móvil, calculado con la variable V19E_F sobre el universo analítico de registros con códigos válidos 1, 2 o 9.

2.4 Objetivo SMART. Hasta el 30/10/2026 se desarrollarán y evaluarán modelos de clasificación binaria para predecir si una vivienda tiene o no Internet. El modelo seleccionado deberá superar el baseline de la clase mayoritaria y mantener un desempeño equilibrado en la clase sin Internet. El informe final y la visualización se consolidarán hasta el 02/12/2026.

3. Formulación del Problema de Minería de Datos

3.1 Objetivo técnico. Construir y evaluar un modelo que identifique las características asociadas a que una vivienda del departamento de La Paz tenga o no acceso a Internet fijo o móvil.

3.2 Tarea y entidad de análisis. Se aplicará clasificación binaria supervisada. Cada fila representará una vivienda y la variable objetivo será V19E_F: 1 = tiene Internet fijo o móvil y 0 = no tiene Internet fijo ni móvil. Los registros con código 9, sin especificar, no participarán en el entrenamiento.

3.3 Datos iniciales del cálculo. El archivo contiene 1.334.496 registros de viviendas de La Paz. Se excluyen 264.658 registros con campos de Internet vacíos. La resta $1.334.496 - 264.658$ produce un universo analítico de 1.069.838 registros con códigos válidos 1, 2 o 9.

Indicador	Cantidad	Cálculo sobre 1.069.838	Resultado
Con Internet	748.401	$748.401 / 1.069.838 \times 100$	69,95 %
Sin Internet	290.940	$290.940 / 1.069.838 \times 100$	27,19 %
Sin especificar	30.497	$30.497 / 1.069.838 \times 100$	2,85 %
Total analítico	1.069.838	Suma de las tres categorías	100,00 %

Tabla 2. Cálculo del KPI departamental

Fuente. Resumen_Internet_LaPaz_Censo2024 (2).xlsx, hoja Resumen_LaPaz.

Cálculo textual del 27,19 %. El porcentaje se obtuvo dividiendo 290.940 viviendas sin Internet entre 1.069.838 registros del universo analítico y multiplicando el resultado por 100: $290.940 / 1.069.838 \times 100 = 27,19 \%$.

Validación. $69,95 \% + 27,19 \% = 97,14 \%$. El 2,85 % restante corresponde a 30.497 respuestas sin especificar. Las tres proporciones redondeadas suman 99,99 %; la diferencia de 0,01 punto se debe al redondeo independiente, mientras que las proporciones sin redondear suman 100,00 %.

4. Brecha Urbano-Rural y Baseline de Clasificación

4.1 Comparación por área. Los totales urbano y rural suman los 1.069.838 registros del universo analítico. La proporción con Internet se calcula dentro de cada área e incluye la categoría sin especificar en el denominador.

Área	Total analítico	Con Internet	% con Internet	Sin Internet	Sin especificar
Urbana	664.447	558.607	84,07 %	91.874	13.966
Rural	405.391	189.794	46,82 %	199.066	16.531

Tabla 3. Acceso a Internet por área urbana y rural

Fuente. Resumen_Internet_LaPaz_Censo2024 (2).xlsx, hoja Urbano_Rural.

Cálculo urbano. $558.607 / 664.447 \times 100 = 84,07 \%$. En el área urbana, aproximadamente 84 de cada 100 viviendas del universo analítico tienen Internet.

Cálculo rural. $189.794 / 405.391 \times 100 = 46,82 \%$. En el área rural, aproximadamente 47 de cada 100 viviendas del universo analítico tienen Internet.

Brecha digital. $84,07 \% - 46,82 \% = 37,25$ puntos porcentuales. Esta diferencia evidencia una desigualdad territorial que debe considerarse al evaluar el modelo y al priorizar futuras acciones de conectividad.

4.2 Muestra etiquetada para modelado. La clasificación binaria utilizará 1.039.341 registros con respuesta Sí o No: 748.401 con Internet y 290.940 sin Internet. Los 30.497 casos sin especificar quedan fuera del entrenamiento y se conservan en el informe de calidad.

Clase de la variable objetivo	Cantidad	Proporción etiquetada	Uso
1 = Con Internet	748.401	72,01 %	Clase mayoritaria
0 = Sin Internet	290.940	27,99 %	Clase de interés
Total etiquetado	1.039.341	100,00 %	Entrenamiento y evaluación

Tabla 4. Distribución de clases para la clasificación binaria

Fuente. Elaboración propia con las categorías Sí y No de V19E_F.

Baseline técnico. Un clasificador que siempre prediga la clase mayoritaria alcanzaría 72,01 % de exactitud. El modelo propuesto deberá superar esa referencia y, al mismo tiempo, mejorar la detección de viviendas sin Internet mediante recall, F1 y exactitud balanceada.

5. Estrategia, Preparación y Criterios de Éxito

5.1 Fuentes y unidad de análisis. La fuente principal es Vivienda_CPV-2024.csv, filtrada por el código departamental 02 = La Paz. El resumen de control es Resumen_Internet_LaPaz_Censo2024 (2).xlsx. Cada registro representa una vivienda y los códigos geográficos permiten comparar áreas, provincias y municipios.

5.2 Resumen EDA. Se revisaron 1.334.496 registros iniciales; 264.658 se excluyeron por campos de Internet vacíos y 1.069.838 conformaron el universo analítico. V19E_F registra 748.401 casos con Internet, 290.940 sin Internet y 30.497 sin especificar. El acceso llega a 84,07 % en el área urbana y 46,82 % en la rural.

5.3 Variables y prevención de fuga. V19E_F será la variable objetivo. Los predictores podrán incluir área urbano-rural, provincia, municipio, características de la vivienda y variables educativas, laborales y tecnológicas disponibles antes de la predicción. V19E_INETFIJO y V19F_INETMOVIL no se usarán como predictores porque determinan directamente V19E_F y producirían fuga de información.

5.4 Calidad y restricciones. Los códigos 9 se conservarán para el informe de faltantes y se excluirán del entrenamiento. Los códigos geográficos se tratarán como categorías. La partición de datos será estratificada para mantener la proporción de ambas clases y cualquier imputación o codificación se ajustará solo con el conjunto de entrenamiento.

Paso	Acción	Control de calidad
1. Delimitar	Filtrar La Paz y auditar códigos de Internet.	Conciliar 1.334.496, 264.658 y 1.069.838.
2. Etiquetar	Recodificar V19E_F como 1 = Sí y 0 = No.	Excluir 30.497 casos sin especificar.
3. Preparar	Imputar, codificar categorías y escalar si corresponde.	Evitar fuga y ajustar transformaciones en entrenamiento.
4. Particionar	Separar entrenamiento, validación y prueba de forma estratificada.	Mantener una prueba final sin reutilizar.
5. Modelar	Comparar regresión logística, árboles y ensambles.	Documentar hiperparámetros y semilla.
6. Evaluar	Comparar con 72,01 % y analizar errores.	Reportar recall, F1, exactitud balanceada y matriz.

Tabla 5. Flujo propuesto de preparación, modelado y evaluación

Fuente. Elaboración propia según CRISP-DM.

Criterio de éxito. El modelo deberá superar el 72,01 % de exactitud del clasificador mayoritario y mostrar una mejora útil en la identificación de la clase sin Internet. La selección no se basará solo en exactitud: se compararán recall y F1 de la clase 0, exactitud balanceada, matriz de confusión y estabilidad entre particiones.

6. Plan de Trabajo, Entregables y Cierre

Fase	Entregable o hito	Fecha	Responsable
1. Negocio	Project Charter aprobado	28/08/2026	Todo el equipo
2. Datos	Análisis exploratorio EDA	04/09/2026	Galilea / Alex
3. Preparación	Limpieza y preprocesamiento	18/09/2026	Alejandro / Galilea
4. Modelado	Entrenamiento y ajuste	02/10/2026	Cristopher / Alejandro
5. Evaluación	Evaluación e interpretación	16/10/2026	Alex / Cristopher
6. Despliegue	Informe final y visualización	02/12/2026	Limber / equipo

Tabla 6. Cronograma de trabajo según CRISP-DM

Fuente. Elaboración propia. Se conservan las fechas de las fases 1 a 5 y se actualiza la fase 6. **Base analítica reproducible.** Conjunto etiquetado de 1.039.341 viviendas, diccionario de variables, reglas de exclusión, registro de faltantes y transformaciones reproducibles.

Modelo y evaluación. Comparación de modelos, hiperparámetros, baseline mayoritario, métricas por clase, matriz de confusión e interpretación de los factores asociados al acceso.

Producto de decisión. Informe y visualización que muestren el KPI departamental, la brecha urbano-rural, la importancia de variables y la distribución territorial de las predicciones.

Ética. Los datos son públicos y anonimizados. No se intentará reidentificar viviendas. Se revisarán errores por área urbana y rural para evitar que el promedio general oculte un desempeño deficiente en la población rural.

Limitaciones. El Censo informa tenencia declarada, pero no mide velocidad, calidad, precio, señal ni cobertura física. El modelo identificará asociaciones y probabilidades; no demostrará causalidad ni sustituirá estudios de ingeniería, costos o validación territorial.

Conclusión. El KPI departamental muestra 69,95 % de viviendas con Internet, 27,19 % sin Internet y 2,85 % sin especificar. El acceso urbano alcanza 84,07 % y el rural 46,82 %, una brecha de 37,25 puntos. Sobre los casos etiquetados, el baseline de clasificación es 72,01 %; superarlo con buena detección de la clase sin Internet será la referencia mínima del modelado.

BIBLIOGRAFÍA

Instituto Nacional de Estadística. Censo de Población y Vivienda 2024: base CSV, cuestionario y diccionario. [Portal de descargas del Censo 2024](#).

Equipo del proyecto. Resumen_Internet_LaPaz_Censo2024 (2).xlsx: consolidado departamental, urbano-rural, provincial y municipal, 2026.

Equipo del proyecto. Proyecto DM, Fase 1: Comprensión del Negocio. UNIFRANZ, 2026.